

SUMMER COURSE

From Photons to 3D

Week 3 · Classical Computer Vision

獵奇緯



目錄

- 01 課程地圖
- 03 Part 1 · 深度如何在投影中消失
- 05 Part 3 · 從像素變化取得局部證據
- 07 Part 5 · 從棋盤反推相機
- 09 Part 7 · 一條輪廓，補足邊緣
- 02 Part 0 · 影像作為量測
- 04 Part 2 · 光如何變成亮度
- 06 Part 4 · 座標系、外參與完整相機模型
- 08 Part 6 · 用第二隻眼買回深度
- 010 收束

SECTION 01

課程地圖



01

從 photons 到 3D，反向問題沒有唯一答案

$$\pi : (\text{geometry, material, illumination, camera}) \rightarrow I(u, v)$$

→ Forward · rendering

給定世界與相機，物理規則決定像素。

← Inverse · vision

只看像素，要猜回世界。不同世界可產生同一張圖。

⚙️ 我們的策略

限縮模型、加入假設、增加量測，然後估計。

Classical vision 明確寫下：哪些答案在目前證據下仍然可能。

主線：資訊先被成像銷毀，再被我們逐段贖回

上半場 · 損失的帳 · Part 0 到 2

像素只是量測，語意不在陣列裡。

投影的那個除法，把深度商掉了。

光度把材質、法向、光源壓成一個 scalar。

下半場 · 贖回的代價 · Part 3 到 7

局部證據：gradient 撐起 edge、corner、line。

標定：賭棋盤是平面，換回 K 與 pose。

雙目：用第二個視角，買回深度。

輪廓：量測不足之處，用 prior 補。

① Info

對應的 lab：① Color ② Local geometry：edge / corner / line ③ Calibration：
 K 、pose、reprojection ④ Homework：Snake

SECTION 02

Part 0 · 影像作為量測



02

■ 這張圖裡「真的」有一條白線嗎？



⚠ 注意

相機量到的是規則網格上的 RGB 數字。車道線是我們對數字提出的世界解釋。

一張數位影像是一個離散函數

$$I : \Omega \subset \mathbb{Z}^2 \rightarrow [0, 255]^3, \quad I(u, v) = (R, G, B)$$

domain

(u, v) 是 pixel index :
向右、向下。


range

每個位置只存有限精度的
sensor value。

語意不在陣列裡

物體、邊界、距離都要
靠模型推論。

量測不足時，先做帳



$I = \rho E_0 \max(0, \cos \theta)$ ：一個方程，兩個未知數

固定 I ， ρ （材質）與 E_0 （光源強度）只被反比約束住：曲線上每一點都是合法解，單張影像的 photometric 量測天生 under-determined。

估計問題的骨架

$$\hat{z} = \arg \min_z D(\text{measurement}, \text{model}(z))$$

constraints 與 prior 把「等高線上的一點」收斂成「唯一可信的 z 」，例如假設 ρ 分段常數、或多視角共享同一個 ρ 。


SECTION 03

Part 1 · 深度如何在投影中消失



03

Pinhole camera：一條 ray 對應一個像素



C: camera center · X: world point · projection ray → image plane · Olaf Peters · CC BY-SA 4.0

$$x = f \frac{X_c}{Z_c}, \quad y = f \frac{Y_c}{Z_c}, \quad Z_c > 0$$

Info

虛擬 image plane 放在相機前方，避免倒像的負號。它在幾何上與真實 sensor 等價。

■ 手算一次：foreshortening 只來自那個除法

$$f = 20 \text{ mm}, \quad X_c = (100, 50, 1000) \text{ mm}$$

原始深度

$$x = 20 \cdot 100 / 1000 = 2 \text{ mm}$$

$$y = 20 \cdot 50 / 1000 = 1 \text{ mm}$$

移到兩倍遠 (100, 50, 2000)


$$x = 20 \cdot 100 / 2000 = 1 \text{ mm}$$

$y = 0.5 \text{ mm}$ ， 像縮成一半。

❶ Info

(x, y) 仍是成像平面上的 metric 座標 (mm) ，還不是 pixel。perspective foreshortening 整個現象，只來自 $1/Z_c$ 這一個除法。

同一條 ray 上的點，投影完全相同



$C \rightarrow X \rightarrow \lambda X$: positions on one projection ray share the image point · Olaf Peters · CC BY-SA 4.0

尺度不變 $\Rightarrow$ 深度被刪除

$$(X_c, Y_c, Z_c) \rightarrow \left(\frac{X_c}{Z_c}, \frac{Y_c}{Z_c} \right)$$

對任意 $\lambda > 0$ ， $\lambda(X_c, Y_c, Z_c)$ 與原點落在同一條 ray，映到同一個像素。三維進、二維出：沿 ray 的深度是被投影方程直接消掉的自由度，不是雜訊蓋掉的。

除法還製造第二個麻煩：非線性

幾何損失 · 上一頁

深度被商掉。這是資訊論的缺口，代數救不回來。

代數麻煩 · 這一頁

$(X_c, Y_c, Z_c) \rightarrow (X_c/Z_c, Y_c/Z_c)$ 含 Z_c 的除法。接下來要串接座標變換、解線性方程組，除法會破壞線性結構。

策略：升一維，再把尺度「商」掉。除法不會消失，但可以被推遲到最後一步。

齊次座標的地基：一個等價關係

$$[x, y, w]^T \sim [\lambda x, \lambda y, \lambda w]^T, \quad \lambda \neq 0, \quad \text{in } \mathbb{R}^3 \setminus \{0\}$$

反身 reflexive

取 $\lambda = 1$: $p = 1 \cdot p$, 故 $p \sim p$ 。

對稱 symmetric

$q = \lambda p$ 且 $\lambda \neq 0 \rightarrow \lambda^{-1}$ 存在 :
 $p = \lambda^{-1} q$ 。

傳遞 transitive

$q = \lambda p, r = \mu q \rightarrow r = \mu \lambda p$, 且
 $\mu \lambda \neq 0$ 。

⚠ 注意

$\lambda \neq 0$ 不是小字：對稱性的證明用到 λ^{-1} 。零向量也必須排除，乘任何尺度仍是零，定不出一條過原點的方向。

■ $\mathbb{P}^2$ 是商空間：一條過原點的直線，是一個點

$$\mathbb{P}^2 = (\mathbb{R}^3 \setminus \{0\}) / \sim$$

equivalence class = 過原點的直線

$[2, 1, 1]^T, [4, 2, 2]^T, [-2, -1, -1]^T$ 是 $\mathbb{R}^3$ 裡三個不同向量，卻在同一條過原點的直線上，同一個 projective point 的三個代表。

自由度的帳

三個座標，扣掉一個無意義的共同尺度，剩兩個自由度。上標 2 由此而來。

① Info

「商」讀作：把相差非零尺度的向量當成同一個元素。homogeneous coordinates 是從 class 裡任選的代表，代表可換，點不變。

Dehomogenize : 在 class 裡選 $w = 1$ 的代表

$w \neq 0$: 取 $\lambda = 1/w$

$$[x, y, w]^T \sim \left[\frac{x}{w}, \frac{y}{w}, 1\right]^T$$

$[4, 2, 2]^T \rightarrow (2, 1)$ 。除法沒有消失，它被推遲成「最後選一次代表」。

$w = 0$: **points at infinity**

無法除，回不到有限平面。平行線因此在 projective plane 有交點，vanishing point 的伏筆。

$$[x_n, y_n, 1]^T \sim [I \mid 0][X_c, Y_c, Z_c, 1]^T$$

① Info

左右相差尺度 Z_c : 數值不同、屬同一個 class、代表同一個 image point，equality up to scale 的完整意思。

從 metric image plane 到 pixel

$$K = \begin{pmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix}, \quad [u, v, 1]^T \sim K[X_c, Y_c, Z_c]^T$$

f_x, f_y

以 pixel 表示的焦距。
它吸收 sensor pitch。

(c_x, c_y)

principal point，不必
剛好落在影像中心。

s

pixel 軸的 skew。現代
相機通常接近零。

把 K 展開：每個參數都有物理身分

$$u = f_x x_n + s y_n + c_x, \quad v = f_y y_n + c_y$$

f_x 吸收了兩個物理量

$$f_x \approx f(\text{mm}) \cdot \frac{W_{\text{px}}}{W_{\text{mm}}}$$

物理焦距與 sensor pixel pitch 一起被打包成「以 pixel 計的焦距」。

f_x 順手給出視角

$$\text{FOV}_x = 2 \operatorname{atan}\left(\frac{W}{2f_x}\right)$$

f_x 越大視角越窄、投影越大，這是光學幾何，digital zoom 只是裁切，與此式無關。

① Info

$s \approx 0$ 仍照估不硬設：讓資料自己說它是零，比假設多一層驗證。

Weak perspective：把 $1/Z$ 凍結成常數的近似

$$\frac{1}{Z} \approx \frac{1}{Z_0} - \frac{Z-Z_0}{Z_0^2}, \quad \text{當 } |\Delta Z| \ll Z_0$$

近似成立時

所有點共用同一個 $1/Z_0$ ：投影變線性，平行線保持平行、大小不隨深度變。

更極端

orthographic projection：直接丟掉縮放，只留 (X, Y) 。

但別忘了

calibration 與 stereo 賴以取得深度的，恰恰是被近似掉的那個透視除法。

⚠ 注意

遠距離窄視角的辨識任務可以用 weak perspective，三維重建必須用完整 perspective model。

為什麼 distortion 只含 r 的偶數次方？

1 · 旋轉對稱

鏡片是旋轉對稱的，畸變量只能是離 principal point 距離 r 的函數。

2 · 光滑性

要求映射在直角座標 (x_n, y_n) 下光滑，而 $r = \sqrt{x_n^2 + y_n^2}$ 本身在原點不可微。

3 · 結論


展開式只能含 $r^2 = x_n^2 + y_n^2$ 的多項式，即 r 的偶數次方。

$$x_d = x_n(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + \text{tangential terms}$$

① Info

教科書模型的形狀不是湊出來的：對稱性 + 光滑性把函數空間篩到只剩這一族。

鏡頭模型加入 radial distortion



Barrel distortion · WolfWings · Public domain

半徑越大，位移越大

$$r^2 = x_n^2 + y_n^2, \quad x_d = x_n(1 + k_1 r^2 + k_2 r^4 + \dots)$$

位移量是 r 的偶次多項式：中心不動，邊緣被系統性地往外（barrel， $k_1 > 0$ ）或往內（pincushion， $k_1 < 0$ ）推。

⚠ 注意

本週 calibration 刻意 pinhole-only，不估 distortion，residual 若呈上圖這種放射狀分佈，就是模型漏了這一項，不是 optimizer 壞掉。

SECTION 04

Part 2 · 光如何變成亮度



04

Pixel value 是一條非線性 response chain 的輸出

$$I(u, v) = g(k \cdot E(u, v) \cdot \Delta t), \quad g \text{ 單調但非線性}$$

E · irradiance

落在 sensor 的單位面積光功率，正比於場景 radiance L 。

$k, \Delta t$

gain (ISO) 與曝光時間，是相機自己選的量測參數。

g · response curve

量化、tone curve、white balance，JPEG 還疊加 gamma。

⚠ 注意

$I(u, v)=200$ 是這條鏈的輸出，不是材質亮度：同一個 E ，改變 k 、 Δt 或 g ，讀數就跟著變。


三個常被混用的量，單位先分清

量	定義	單位
radiance L	沿特定方向、單位立體角、單位投影面積的光功率	$\text{W} \cdot \text{sr}^{-1} \cdot \text{m}^{-2}$
irradiance E	表面單位面積接收的光功率，理想透鏡下 $E \propto L$	$\text{W} \cdot \text{m}^{-2}$
pixel value I	E 經曝光、gain、response curve、量化後的數值	無單位

⚠ 注意

classical vision 公式常假設 linear camera response：raw 影像大致成立，JPEG 已經過 tone curve，公式的保固條件從這裡開始。

Lambert cosine law：入射角先決定收到多少光



PBRT 3e · Fig. 5.7 · Pharr, Jakob, Humphreys · CC BY-NC-SA 4.0

幾何推導

$$E = E_0 \max(0, n \cdot l)$$

等寬平行光束斜射到表面時，照到的面積隨 $\frac{1}{\cos \theta}$ 展開，單位面積收到的功率就隨 $\cos \theta$ 下降， $\theta > 90^\circ$ 表示背對光源，直接取 max 截斷成 0。

「斜著看所以變暗」不精確：這條式子裡沒有觀看方向 v ，變暗首先是**入射幾何**，與你從哪個角度看無關。

■ ρ/π 的 π 是能量守恆逼出來的

$$\int_{\text{hemi}} \cos \theta \, d\omega = \int_0^{2\pi} d\varphi \int_0^{\pi/2} \cos \theta \sin \theta \, d\theta = 2\pi \cdot \frac{1}{2} = \pi$$

BRDF 是常數

Lambertian： $f_r = \rho/\pi$ ，出射 radiance 與方向無關。

出射總功率

radiance 對半球做 cosine-weighted 積分，常數提出，正好乘上 π 。

收支平衡


反射功率恰為入射的 ρ 倍， $\rho \in [0, 1]$ 才配叫 albedo。

⚠ 注意

若 BRDF 直接取 ρ 不除 π ，反射功率會是入射的 $\pi\rho$ 倍，能量無中生有。

Lambertian：跨視角一致性的假設

$$I(p) \propto \rho(p) L \max(0, n(p) \cdot l) + I_{\text{ambient}}$$



Lambertian · glossy · specular · Vierge Marie / Grap-wh · CC BY-SA 4.0

兩種 BRDF 的差別

Lambertian 的 BRDF 是常數 $\frac{\rho}{\pi}$ ，出射 radiance 對觀看方向不變（左圖是半圓）。specular 把能量集中在鏡面反射方向附近（右圖的窄瓣）。stereo matching 假設外觀左右一致，正是在賭 Lambertian 這一半。

歧義的簿記：一個 scalar，五個以上的未知數

$$\underbrace{I(p)}_{\text{1 個量測}} \propto \underbrace{\rho(p)}_1 \cdot \underbrace{L}_1 \cdot \max \left(0, \underbrace{n(p)}_2 \cdot \underbrace{l}_2 \right) + I_{\text{ambient}}$$

「這個 pixel 比較暗」

可能是材質深、表面轉開、光源弱、在陰影裡，單一 scalar 幾乎不攜帶資訊。

shape from shading 的存在理由

假設 albedo 均勻、光源已知、表面光滑，自由度才被砍到可辨識。

模板第一次上場

量測不夠，就得用假設補，假設哪條不成立，重建就跟著失效。

Lambertian 的反例目錄：假設破產的四種方式

specular

金屬、玻璃、濕表面：亮度隨觀看方向劇烈變化，高光跟著視角跑。

cast shadow

別的物體擋光。邊界銳利，與表面自身幾何無關。

attached shadow

表面自己背光： $n \cdot l < 0$ ，就是 cosine law 裡的 $\max(0, \cdot)$ 。

interreflection

相鄰表面互相照亮，單一光源模型失效。

⚠ 注意

Part 6 的 stereo 靠「同一世界點左右外觀相似」認人，一個只在左眼出現的高光，會讓 matching 在那裡直接失明。

RGB → grayscale：三種定義，三種立場

$$\text{Average} : \frac{R+G+B}{3} \quad \text{Lightness} : \frac{\max + \min}{2} \quad \text{Luminosity} : .299R + .587G + .114B$$

Average

三個 channel 等權，假裝 sensor 三色同等重要。

Lightness

只看最亮與最暗 channel 的中點，丟掉中間值。

Luminosity · BT.601

權重反映人眼對綠敏感、對藍遲鈍。本週程式用這個。

⚠ 注意

三者都是實用 signal conversion，都不是 photometric calibration：後者還需要線性化與光譜響應。

Color lab : representation 決定「距離」的意義

RGB → intensity

$$Y = .299R + .587G + .114B$$

luma 是實用轉換，不等於 albedo 或照度。

HSV hue 是圓，不是線

$$d(h_1, h_2) = \min(|h_1 - h_2|, 360^\circ - |h_1 - h_2|)$$



350° ↔ 10°: shortest arc crosses 0° · 8 leaf-clover · CCO

Info

Color notebook 讓你比較三種 grayscale、histogram 與 RGB↔HSV。它們改變表示與操作，保留相同的場景資訊量。

| Histogram 商掉了全部空間結構

$$h(k) = \#\{(u, v) : I(u, v) = k\}$$

對 pixel 重排不變

任意打亂 pixel 位置，histogram 一個 bin 都不動。「對所有排列不變」的精確意思：空間結構被商掉了。

推論：shape 讀不回來


兩張幾何內容完全不同的影像可以有相同 histogram，構造法就是打亂 pixel。

① Info

它適合觀察 sensor value 的分布。Part 7 的 Otsu threshold 建在它之上，屆時要記得這個先天限制。


SECTION 05

Part 3・從像素變化取得局部證據



05

Gradient 是局部一階模型



Blue arrows: ∇I · isophotes are perpendicular · Finallymadeanaccount · CC BY-SA 4.0

Taylor 一階展開

$$I(x + \delta x, y + \delta y) \approx I(x, y) + \nabla I^T \delta$$

$$\nabla I = [I_x, I_y]^T, \quad |\nabla I| = \sqrt{I_x^2 + I_y^2}, \quad \varphi = \text{atan2}(I_y, I_x)$$

gradient 指向最陡上升，等值線（同亮度）的切線方向與它正交，這就是圖中 edge 與 ∇I 垂直的原因。

| Sobel：平滑與微分合在一個 kernel

先問為何要平滑

微分放大高頻。sensor noise 正是高頻。

$$\partial(G_\sigma * I) = (\partial G_\sigma) * I$$

Sobel G_x

$$\begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix}$$

垂直方向 $[1,2,1]$ 平滑，水平方向中央差分。

Separability : Sobel 是一個 outer product

$$\begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} \otimes \begin{pmatrix} -1 & 0 & 1 \end{pmatrix}$$

分解的讀法

垂直方向做 $[1, 2, 1]$ 平滑、水平方向做 $[-1, 0, 1]$ 中央差分，兩個一維操作的合成。

計算的紅利

每 pixel 成本從 $O(k^2)$ 降到 $O(k)$ ：3×3 差別小，大 kernel 是實質加速。

 G_y

就是轉置：平滑與差分交換方向，比較上下。

Info

Gaussian 本身也 separable，「先平滑再微分」整條管線都能拆成一維摺積。

■ Canny 的起點：把「好偵測器」寫成最佳化問題

detection

不漏掉真邊、不把 noise 檢成邊，訊噪比要高。

localization

回報的位置要貼近真實邊緣，定位方差要小。

Canny (1986) 證明：同時最佳化這兩個準則，最優 *filter* 可用 ***Gaussian*** 的導數逼近。

① Info

所以「先 Gaussian 平滑再 Sobel」不是工程慣例的堆疊，而是最佳化問題的近似解，剩下的工作是把厚山脊變成細曲線。

| Canny：把一條厚山脊壓成可追蹤曲線

1 · magnitude

找可能的亮度變化。

2 · NMS

沿 gradient 方向只留局部極大，thinning。

3 · hysteresis

strong seed 連到的 weak pixel 才保留。

⚠ 注意

low 太低會把 clutter 接進來。high 太高會讓真邊沒有 seed。hysteresis 是 connected-components 問題。

Hysteresis 是一個圖論問題

定義圖

頂點：strong 與 weak pixels（兩個 threshold 分出三類）。

邊：8-鄰接關係。

保留：所有**含至少一個 strong 頂點**的 connected component。

演算法

```
for each strong pixel s not yet visited:  
  BFS/DFS from s over strong U weak  
  mark the whole component as edge
```

線性時間 $O(V + E)$ 完成。

high 太高

真邊沒有任何 seed，整個 component 被丟。

low 太低

大量 weak 頂點連進有 seed 的 component。

high = low

連通性資訊完全沒被用到，退化回單一 threshold。


Corner：移動哪個方向都應該看起來不同

$$E(\delta) = \sum_w [I(x + \delta) - I(x)]^2 \approx \delta^T M \delta$$

$$M = \sum_w \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix}, \quad \lambda_{\min} \leq d^T M d \leq \lambda_{\max}, \quad \|d\| = 1$$

eigenvalues	local geometry	meaning
both small	flat	no reliable localization
one large	edge	aperture problem
both large	corner	all directions constrained

Harris：不用求特徵值，也能辨認角點



Sánchez, Monzón, Salgado · IPOL Fig. 5 · CC BY-NC-SA 3.0

$$R = \det(M) - k \operatorname{tr}(M)^2 = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2$$

$\det, \operatorname{tr}$ 是 eigenvalue 的不變量，避免逐 pixel 做特徵分解。令 $m = \lambda_2 / \lambda_1$ ， $R = 0$ 化簡成 $km^2 + (2k - 1)m + k = 0$ ：對常用 $k = .04$ 解出兩個根 $m \approx .044, 22.96$ （互為倒數），對應圖中兩條射線，之間才是 $R > 0$ 的 corner 錐，貼近任一軸的窄帶是 $R < 0$ 的 edge。

Info

Harris response 後仍須 spatial NMS，讓每個真角落回傳單一局部峰值。

直線的參數化：先選對座標

$y = mx + b$ 不及格

垂直線的 $m \rightarrow \infty$ ，參數空間無界，道路影像裡最重要的線剛好接近垂直。

normal form

$$\rho = x \cos \theta + y \sin \theta$$

θ 是法線方向、 ρ 是原點沿法線到直線的有號距離：
所有直線都被有界參數覆蓋。

重複表示

$(\rho, \theta) \sim (-\rho, \theta + \pi)$ ：法線轉向、距離變號，同一條線。慣例取 $\theta \in [0, \pi)$ 。

參數的界

原點取影像左上角時 $\rho_{\max} = \sqrt{(W-1)^2 + (H-1)^2}$ ，不超過對角線。

Hough transform：共線關係在參數空間交會




Image points $\rightarrow$ sinusoidal votes $\rightarrow$ shared peak · NekojaNekoja · CC BY-SA 3.0

對偶：點 $\leftrightarrow$ 曲線

$$\rho = x \cos \theta + y \sin \theta$$

固定 image space 的一點 (x, y) ，這條式子描述它「可能屬於」的所有直線，畫在 (ρ, θ) 空間是一條正弦曲線。左圖三個共線點各自的曲線，在同一個 (ρ, θ) bin 相交，共線關係被翻譯成投票峰值。

⚠ 注意

(ρ, θ) 與 $(-\rho, \theta + \pi)$ 是同一條線。量化太粗會合併候選。量化太細會稀釋票數。

投票演算法：把連續對偶離散化

Hough-Vote

```
for each edge point (x_i, y_i):  
    for j = 0, ..., N_θ - 1:  
        θ_j = j · Δθ  
        ρ = x_i cos θ_j + y_i sin θ_j  
        k = floor((ρ + ρ_max) / Δρ)  
        A[k, j] += 1
```

格子

$$\Delta\theta = \pi/N_\theta, \Delta\rho = 2\rho_{\max}/N_\rho^\circ$$

成本

時間 $O(N_{\text{edges}}N_\theta)$ 、空間 $O(N_\rho N_\theta)$ ，sin, cos 先建表。

① Info

一個 edge point 不知道自己屬於哪條線，所以沿它整條離散 sinusoid 逐格投票， $A[k, j]$ 最後等於支持該直線的 edge points 數。

■ 手算一個最小例子：峰值如何形成

$(1, 2), (3, 2), (5, 2)$ 都在 $y = 2$ 上

$\theta = \pi/2$ 時

$\cos \theta = 0, \sin \theta = 1$ ，三點都算出 $\rho = y = 2$ ：bin $(\rho = 2, \theta = \pi/2)$ 收到 **3 票**。

其他角度

三點通常算出不同的 ρ ，票散進不同格子，只有真實直線的參數格會累積。

⚠ 注意

真實影像有 noise、邊緣厚度、量化誤差：sinusoids 只會在一小片鄰域靠攏，不會精確穿過同一個 bin，這是下一頁後處理存在的理由。

Accumulator 的後處理與量化取捨

為何不能只做 threshold

同一條真線在相鄰 bins 形成一團高票區，直接 threshold 會回報多條幾乎相同的線。

2D NMS

只留 (ρ, θ) 鄰域內的局部最大，再依票數排序、套 vote threshold。

週期邊界

θ 的首尾是相鄰方向：NMS 要處理 $[0, \pi)$ 的 wrap-around 與 ρ 的符號翻轉。

格子太粗

不同直線的票混進同一格，參數估計也粗。

格子太細

同一條線的票被 noise 打散到相鄰格，峰值反而變低，記憶體與計算同時上升。

讓 gradient orientation 替你省票

方向資訊

edge 的 gradient 方向 φ_i 正是線的法線方向：只需對 $\theta \approx \varphi_i$ 附近的 m 個 bins 投票，成本從每點 N_θ 降到 m 。

magnitude 加權

$$A[k, j] += |\nabla I(x_i, y_i)|$$

強 edge 影響力大，但高對比短線會壓過低對比長線。

投票權重的選擇，其實是在定義「**支持一條線的證據**」如何計量。

從無限長直線到影像裡的線段

1 · 收集支持點

$$|x_i \cos \theta + y_i \sin \theta - \rho| < \varepsilon$$

2 · 投影到線方向

$$d = (-\sin \theta, \cos \theta), s_i = d^T(x_i, y_i), \text{ 排序。}$$

3 · gap 切段

相鄰 s_i 的 gap 超過門檻就切，丟掉太短、支持點太少的 run。

① Info

lane marking 天生斷裂：gap threshold 決定相鄰標線合併或分開，minimum length 排除 clutter。另有 Probabilistic Hough：抽樣投票、直接輸出 endpoints，用函式庫前先確認是哪個版本。

Local geometry lab：同一份 gradient，三種不同問題

Canny

Sobel → NMS →
hysteresis。看
threshold 對連通性的
影響。

Harris


structure tensor →
response → NMS。看
尺度與稀疏度。

Hough

Canny points →
accumulator → peaks
→ segments。看量化
與 vote threshold。

SECTION 06

Part 4 · 座標系、外參與完整相機模型



先說清楚「誰被誰看見」

$$X_c = RX_w + t, \quad R \in \text{SO}(3)$$

rotation

$R^T R = I$ 、 $\det R = +1$ ：保長度與方向，
排除鏡射。

translation

相機中心在 world 是 C_w 時：

$t = -R C_w$ 。

$$T_{cw} = \begin{pmatrix} R & t \\ 0 & 1 \end{pmatrix}, \quad T_{wc} = T_{cw}^{-1}$$

t 是什麼？把相機中心代進去就知道

推導：相機中心必須映到原點

$$0 = RC_w + t \implies t = -RC_w$$

所以 t **不是**「相機的位置」，相機在 world 的位置是 $C_w = -R^T t$ 。

下標紀律：像分數約分

$$T_{cw} T_{wr} = T_{cr}$$

目的地在左、來源在右，串接時中間的 w 對消。
矩陣從右往左作用。

⚠ 注意

說「外參是相機的位置」之前必須先聲明變換方向，否則就是在賭五五開，多 frame 串接的 bug 大半死在這裡。

完整 camera matrix 把三段流程壓成一行

$$\tilde{x} \sim K[R \mid t]\tilde{X}_w = P\tilde{X}_w$$

extrinsic

world point $\rightarrow$ camera
frame

perspective divide

camera frame $\rightarrow$
normalized image

intrinsic

normalized image $\rightarrow$
pixel

× 危險

矩陣式很方便，但 debug 時必須把中間的 `z_c > 0` 與 dehomogenize 明確攤開。

■ Cheirality：數學允許、物理不允許的正負號

投影方程是對稱的

$Z_c < 0$ （點在相機後方）照樣能除出一組 (u, v) ，
方程不抱怨，但那不是影像。

物理不是

可成像的點必須在相機前方。這個「選出物理解」
的約束叫 **cheirality constraint**。

① Info

Part 5 從 homography 分解 pose 時， $\pm H$ 是同一個映射，卻給出棋盤在相機前／後
兩組解，靠 cheirality 挑對的那組。

旋轉的表示法是 optimizer 的設計選擇

$$R(\theta k) = \exp(\theta[k]_{\times}) = I + \sin \theta[k]_{\times} + (1 - \cos \theta)[k]_{\times}^2$$

Euler angles

直觀，但有順序約定與 gimbal lock。

axis-angle θk

三個自由度，正好等於 $SO(3)$ 的切空間維度。

quaternion

組合方便，但有 unit constraint 與雙覆蓋。

① Info

$[k]_{\times}$ 是反對稱矩陣 ($[k]_{\times}^T = -[k]_{\times}$)， $\exp([k]_{\times} \theta)$ 的冪級數摺疊成上式 (Rodrigues formula)，這正是為什麼 axis-angle 的三個分量可以直接當成無約束的優化變數，而九個矩陣元素不行。

SECTION 07

Part 5・從棋盤反推相機



07

已知、共享、每張都不同

known observations

棋盤平面點 $(X, Y, 0)$ 與影像角點 (u, v) 。

per-view

每張各自的 pose (R_i, t_i) 。

shared

一組 intrinsics K ：
 f_x, f_y, c_x, c_y, s 。

Info

這是超定 estimation：每個角點給兩個量測，資料多於未知數。多樣 view 帶來獨立約束。

■ 平面棋盤把 camera equation 化成 homography

$$\tilde{x} \sim K[r_1, r_2, r_3, t][X, Y, 0, 1]^T = H[X, Y, 1]^T$$

H 的自由度

3×3 matrix，扣除整體 scale 後有 8 個。

最小資料

四組不共線平面點對應，原則上即可定出一個 H。

關鍵分解

$H \sim K[r_1, r_2, t]$ ：每張 H 都含同一個 K。

消掉 up-to-scale：外積歸零的技巧

$$\tilde{x} \sim H\tilde{X} \iff \tilde{x} \times (H\tilde{X}) = 0$$

為什麼用外積

兩個 homogeneous 向量
「相等 up to scale」= 平行 =
外積為零。討厭的未知尺度被
消掉了。

三條方程、秩 2

外積給三個分量，但它們以 $\tilde{x}$
的座標為係數線性相關，每組
對應只取兩條獨立方程。

堆成線性系統

H 的 9 個元素攤平成 h ，每組
對應貢獻 2 列： $Ah = 0$ ， A 是
 $2n \times 9$ 。

① Info

8 個自由度、每組對應 2 條方程 $\Rightarrow$ 4 組不共線點原則上定出 H ，棋盤給幾十組，多的全部拿去對抗 noise。

DLT：把 up-to-scale 對應變成最小奇異向量

$$\tilde{x} \times (H \tilde{X}) = 0 \rightarrow Ah = 0 \rightarrow \min_{\|h\|=1} \|Ah\|^2$$

解

$\|Ah\|^2 = h^T (A^T A) h$ 是 Rayleigh quotient，解為 $A^T A$ 最小特徵值的特徵向量，等價於 A 最小 singular value 對應的 right singular vector。

數值衛生

先平移到質心、縮放到平均距離 `sqrt(2)`，再 denormalize `H=T_x^-1 H' T_X`。

❶ Info

與 Harris 用 M 的最大 eigenvalue 判斷角點，是同一個「二次型 + 特徵分解」骨架的兩個角落：一個取最大，一個取最小。

為什麼一定要 **normalize**：條件數的平方懲罰

$$\kappa(A^T A) = \kappa(A)^2$$

地雷

world 座標幾公分、pixel 座標幾千：A 的 columns 差好幾個數量級，conditioning 在成 normal equation 的瞬間**平方惡化**。

Hartley normalization 處方

兩邊的點各自平移到質心、isotropic 縮放到平均距離 $\sqrt{2}$ ，在規範化座標估 H' ，再剝回：

$$H = T_x^{-1} H' T_X$$

幾何問題一個字都沒變，變的只是線性系統的條件數。「**先把資料擺到數值友善的位置**」在所有幾何視覺問題裡通用。

■ Zhang：旋轉的正交性變成對 K 的線性約束

$$B = K^{-T} K^{-1}$$

$$h_1^T B h_2 = 0, \quad h_1^T B h_1 - h_2^T B h_2 = 0$$

每個 view

由

`r_1 perpendicular r_2`

與等長性貢獻兩條約束。

至少三個 view

對稱 B 有 6 項、扣
scale 剩 5 個自由度。

資料收集

tilt、位置、影像覆蓋要多樣。避開近似重複姿態。

取回 pose，再把幾何誤差磨到底

pose from H

$$K^{-1} H = [\lambda r_1, \lambda r_2, \lambda t]$$

normalize、cross product 補 r_3 ，
再投影回 $so(3)$ 。選正深度符號。

nonlinear refinement

$$\min \sum_{i,j} \| \text{project}(K, R_i, t_i, X_j) - x_{ij} \|^2$$

LM 在 Gauss Newton 的快與
gradient descent 的穩之間調節。

兩個收尾細節：投影回 $SO(3)$ 、挑對符號

noise 讓 r_1, r_2 不再正交

本週程式用 Gram Schmidt 修正，更一般的是 orthogonal Procrustes：SVD $M = U\Sigma V^T$ ，Frobenius 距離最近的旋轉是 UV^T （修正 $\det$ 符號）。

Part 4 的伏筆兌現

$-H$ 與 H 是同一個映射，但兩個符號給出的 pose 一個讓棋盤在相機前方、一個在後方，**cheirality**：選深度為正的那組。

Info

「數學不區分、物理區分」的兩件事在同一步出現：流形約束靠投影修復，符號歧義靠物理挑選。

Algebraic error 與 geometric error 不是同一件事

algebraic · $\|Ah\|$

為了**線性可解**而構造的量。與「影像上差幾個 pixel」沒有直接的度量關係。

geometric · reprojection

$$r_{ij} = \text{project}(K, R_i, t_i, X_j) - x_{ij}$$

我們真正在乎的量，單位是 pixel，但對參數高度非線性，沒有 closed form。

Pattern：線性 *closed-form* (algebraic) 拿**正確 basin 裡的初值**，非線性優化 (geometric) 把誤差磨到底。triangulation、pose estimation、bundle adjustment 全是變奏。

LM：在 Gauss Newton 的 normal equation 裡插入 damping

$$r(x + \Delta) \approx r + J\Delta \rightarrow \min_{\Delta} \|r + J\Delta\|^2 \rightarrow (J^T J)\Delta = -J^T r$$

$$(J^T J + \lambda D)\Delta = -J^T r$$

λ 小 $\rightarrow$ Gauss Newton

信任二階近似，收斂快， $J^T J$
病態或展開失效時亂跳。

λ 大 $\rightarrow$ gradient descent

方向趨近負梯度、步長縮小，
保守但穩。

自適應

試走一步：cost 降 $\rightarrow$ 接受、
調小 λ ，升 $\rightarrow$ 拒絕、調大 λ 。

⚠ 注意

LM 是 local optimizer：起點錯照樣掉進錯的 basin，這正是前面整條線性 closed-form 道路存在的理由。

Calibration lab：把 cost function 畫到影像上

summary

讀 K 、每張 pose 與 overall RMS。

overlay

綠色是觀測點。紅色是重投影點。兩者的連線就是 residual。

diagnostics

逐 view RMS 與 include/exclude。找 outlier 與系統性殘差。

⚠ 注意

低 RMS 仍要搭配參數與 residual 分布檢查。邊緣放射狀殘差提示 distortion。單一 view 特別差時先查觀測與影像品質。

病徵 → 病因：讀 residual 的故障定位表

病徵	先查什麼
單一 view 特別差	那張的角點觀測、motion blur、棋盤不平
殘差在影像四周呈放射狀	lens distortion 缺席的簽名，模型類太小，不是估計壞掉
所有 view 共享一致偏移	座標約定、棋盤點序、principal point
RMS 低到不合理但 f 很怪	資料 degenerate、自由度互相吸收錯誤

「跑完了」和「對了」是兩回事，*fit* 得好從來不等於參數對。

本週 dataset 的判決：殘差自己說了下一步

13 張真實 views

真實影像 + 預先抽好的角點。

overall RMS ≈ 1.55 px

pinhole-only model 收斂後的成績。

邊緣殘差呈放射狀

residual 的空間分布，不只是一個 scalar。

Part 1 的伏筆收回

當初「刻意只估 pinhole」的決定，在這裡兌現成看得見的模型缺漏，下一個該加的成分是 distortion，殘差已經替你決定了。

離開前自問五題

- ① 一張 view 的 world plane $\rightarrow$ image 是哪個變換？
- ② 多 views 間什麼共享、什麼獨立？
- ③ $r_1 \perp r_2$ 怎麼變成對 K 的線性約束？
- ④ closed-form 之後為何還要 refinement？
- ⑤ 為何剔除一張 view 後所有參數都要重估？


SECTION 08

Part 6 · 用第二隻眼買回深度



08

Triangulation：兩條 ray 提供第二個約束




$$X(\lambda_L) = C_L + \lambda_L d_L, \quad X(\lambda_R) = C_R + \lambda_R d_R$$

⚠ 注意

有 noise 時 rays 通常是 skew lines。baseline 太短或物體太遠時夾角太小，深度會非常不穩。

Epipolar geometry 把二維搜尋降成一維



平面決定線

C_L, C_R, X 三點決定一個 epipolar plane，它與每張影像平面的交線就是 epipolar line。這條平面必過 baseline，所以每條 epipolar line 都通過該影像的 epipole (e_L, e_R ：baseline 與影像平面的交點)。正確 match 必落在對應的線上。

$$x_R^T E x_L = 0, \quad E = [t]_{\times} R$$

$$x_{R,\text{pixel}}^T F x_{L,\text{pixel}} = 0, \quad F = K_R^{-T} E K_L^{-1}$$

■ $E = [t]_{\times} R$ ：從三重積讀出它的全部性質

$$x_R \cdot (t \times Rx_L) = 0 \quad (\text{三向量共面} \iff \text{純量三重積為零})$$

線的係數

Ex_L 就是右圖 epipolar line，
 x_R 在線上所以內積為零。

rank 2

$[t]_{\times}$ 秩為 2 $\Rightarrow \text{rank}(E) = 2$ ，
null space 就是 epipole。

尺度不可觀測

t 與場景一起放大 λ 倍，影像
一個 pixel 都不變，重建天生
up-to-scale。

⚠ 注意

想要公尺，必須從外部注入尺度：量 baseline、放已知尺寸的物體，或上其他感測器。Part 1 的 up-to-scale 在這裡收口。

Rectification：把幾何重參數化成水平 scanline




Bild 1/2 = source planes · Epipolarebene = epipolar plane · green planes = rectified · CC BY-SA 3.0

做的事

對每張影像各自施一個 projective warp，虛擬地把兩台相機轉成光軸平行、影像平面共面。這是純粹的 coordinate change，不創造新資訊，代價是重採樣與 invalid border。warp 後所有 epipolar line 都變成水平線，correspondence 只需沿 **u** 搜尋。

Disparity 與深度的反比

$$u_L = f \frac{X}{Z} + c_x, \quad u_R = \frac{f(X-B)}{Z} + c_x$$

$$d = u_L - u_R = f \frac{B}{Z} \quad \rightarrow \quad Z = f \frac{B}{d}$$

near

大 disparity。

far

小 disparity。 `d to 0`
時深度趨向無窮。

error propagation

$|\delta Z| \approx \frac{Z^2}{fB} |\delta d|$ 。遠處誤差平方惡化。

Correspondence 需要外觀假設，也需要知道何時拒答

$$\text{SSD}(x, y, d) = \sum_{(i,j) \in W} \left[I_L(x+i, y+j) - I_R(x-d+i, y+j) \right]^2$$

textureless

沿線 cost 幾乎
不變：aperture
problem。

repeated texture

多個相近極小
值，答案不唯
一。

occlusion / specular

另一眼沒有對
應，或
Lambertian 假
設失效。

consistency check

將不一致區域標
為 invalid。下游
可直接辨識可信
的深度範圍。

Cost 的選擇就是不變性的選擇

cost	對什麼不變	代價
SSD / SAD	什麼都不：假設 brightness constancy	曝光差直接失效
NCC	線性亮度變化 $aI + b$	計算較貴、小 window 不穩
Census	任何保序的亮度變換	只剩排序資訊，弱紋理更難

成本帳

逐 pixel 對視差範圍 D 取 argmin：總成本 $O(H \cdot W \cdot D \cdot |W|)$ 。

升格成 energy

data term 累積 matching cost + smoothness term 懲罰視差跳變，「量測 + 先驗」，Part 7 的 snake 是同一結構的另一個化身。


SECTION 09

Part 7 · 一條輪廓，補足邊緣



09

Active contour 把「合理輪廓」寫成 energy



Green samples: discrete contour converging to the boundary · Dake · CC BY-SA 2.5

三個力的分工

$$E[v] = \int [\alpha |v'(s)|^2 + \beta |v''(s)|^2 + E_{\text{ext}}(v(s))] ds$$

影像項 E_{ext} （黃色箭頭）把離群的頂點拉向邊界，
curvature 項 $\beta |v''|^2$ （紅色箭頭）把尖點拉回鄰居的平均，是平滑 prior，continuity 項 $\alpha |v'|^2$ 鼓勵取樣點間距均勻，避免輪廓在某處擠成一團。

$E[v]$ 是泛函：自變數是一整條曲線

function

$$f : \mathbb{R} \rightarrow \mathbb{R}$$

輸入一個數。極值條件： $f'(x) = 0$ 。

functional

$$E : v(\cdot) \rightarrow \mathbb{R}$$

輸入一條曲線。極值條件：Euler Lagrange 方程。

$$\delta E = 0 \quad \Leftrightarrow \quad -\alpha v'' + \beta v'''' + \nabla E_{\text{ext}} = 0$$

① Info

原論文以半隱式迭代解這條四階方程，本週作業改用 Williams Shah 的離散 greedy，放棄變分機械，直接在離散 energy 上做局部搜尋，極小化同一類 objective。

■ 本週作業：離散 greedy snake

$$E_{\text{snake}} = \sum_i [\alpha E_{\text{cont}}(i) + \beta E_{\text{curv}}(i) + \gamma E_{\text{img}}(i)]$$

每個點的候選 window

窮舉 $(2r+1) \text{ times } (2r+1)$ 位置。三個 energy 各自在 window 中 normalize 到 $[0,1]$ ，再加權選最小。

image energy

$$E_{\text{img}}(v) = -|\nabla(G_{\sigma} * I)(v)|$$

Gaussian 同時降噪、拓寬 edge 的 attraction basin。

三項 energy 逐項推導：每一項都管一件事

continuity · 反聚團

$$E_{\text{cont}}(v) = (\bar{d} - \|v - v_{i-1}\|)^2$$

$\bar{d}$ 是每輪重算的平均鄰點距離：懲罰「偏離平均間距」，避免點被強 edge 吸成一團、留下大段輪廓無人處理。

curvature · 抗彎剛性

$$E_{\text{curv}}(v) = \|v_{i-1} - 2v + v_{i+1}\|^2$$

二階導數的中央差分：三點等距共線時中間點恰是前後平均，此項為零，急彎時暴漲。

⚠ 注意

β 太小，輪廓追著 noise 長鋸齒，太大，把手、凹槽、尖角被 prior 抹掉，**prior 補足資料，也可能壓過資料。**

■ Otsu：一個乾淨的小定理

$$\sigma^2 = \sigma_w^2(t) + \sigma_b^2(t), \quad \sigma^2 \text{ 與 } t \text{ 無關}$$

變異數分解

把總變異數按 threshold t 拆成
組內 + 組間。

對偶

總和固定 $\Rightarrow$ 「最大化組間」 =
「最小化組內」，同一件事。

計算

對 256 個 threshold 掃一遍
histogram： $O(N + 256)$ 。

⚠ 注意

Otsu 繼承了 histogram 的盲點（Part 2）：看分布不看空間，假設前景背景在 intensity 上可分，它不理解物體。

Initializer : blur → Otsu → components → bbox

1 · blur + Otsu

Gaussian 壓噪，
histogram 上取
threshold，得前景
mask。

2 · 8-connected components

又是圖論。丟掉碰邊
界的與太小的。

3 · bbox 聚類


用鄰近性合併，對付
被反光切斷成數塊的
物體。

4 · 矩形重取樣

贏家 cluster 的 bbox
內縮，沿周長均勻取
 N 點。

刻意粗糙，粗糙得有原則：它只負責把矩形放進**正確的 *basin***，不負責解出輪廓。
剩下的路讓 *snake* 自己走。

Initialization 決定你落在哪個 basin



Three initializations follow separate trajectories toward local minima · Jacopo Bertolotti · CCO

greedy snake 是非凸的局部搜尋

每輪只做 block coordinate descent，只能沿 E_{snake} 這條曲面往下走一小步，走不出目前所在的 basin。init 決定初始 x 落在哪一段，粗初始化 (blur $\rightarrow$ Otsu $\rightarrow$ connected components $\rightarrow$ bbox) 的唯一任務，就是把它放進正確 basin，不是先把答案描好。

⚠ 注意

iterations 只能在同一個 basin 內多走幾步，不能修復錯的 objective、錯的 weights，或錯的 initial basin，這對應圖中琥珀色起點：它離目標輪廓不遠，卻已經越過了分隔兩個 basin 的山脊。

Homework notebook：用參數讀懂失敗

parameter	增加時的效果	代價
<code>alpha</code>	點距更均勻	局部伸縮更僵
<code>beta</code>	輪廓更平滑	尖角、凹部被抹掉
<code>gamma</code>	更服從 edge	更容易被內部紋理劫走
<code>sigma</code> , <code>r</code>	吸引範圍／單輪步幅變大	定位變鈍／跳到錯 edge

❶ Info

南瓜、印花箱、手提箱分別測試平滑性、內部 texture 與初始化斷裂。每一種失敗都能對應回 energy 的某一項。

SECTION 010

收束



010

I 同一個 estimation template

模型與量測

pinhole：ray 與投影

calibration：棋盤平面與角點

stereo：兩眼幾何與外觀

snake：影像 gradient 與封閉曲線

假設與診斷

每個解都有 error、residual 或 invalid mask。

模型失效提供下一步的建模方向。


I 好的 *vision* 系統輸出答案，也暴露自己的假設、誤差與不確定性。

References

- Richard Szeliski, **Computer Vision: Algorithms and Applications**, 2nd ed.
- Hartley & Zisserman, **Multiple View Geometry in Computer Vision**, 2nd ed.
- Forsyth & Ponce, **Computer Vision: A Modern Approach**, 2nd ed.
- Zhang (2000), **A Flexible New Technique for Camera Calibration**.
- Canny (1986) , Harris & Stephens (1988) , Kass, Witkin & Terzopoulos (1988) , Otsu (1979).



Q & A



獵奇緯 · Summer Course